

SISTEMATIZACAO_MEC_NomeDoGrupo

Matematica e Estatistica para Computacao - Prof. Romes Heriberto
Laboratorio Estatistico Interativo - versao principal (versao com codigo)

1. Identificacao

Nome do grupo: trabalho individual - Gabriel Richardy

N	Nome completo	Matricula
1	Gabriel Richardy	(SUBSTITUIR matricula)

2. Link dos dados crus

Dataset: Body Performance Data (Kaggle) - 13.393 registros, 10 variaveis numericas e 2 categoricas (gender, class).

<https://www.kaggle.com/datasets/kukuroo3/body-performance-data>

Repositorio GitHub com: nucleo estatistico proprio (nucleo/), interface Streamlit (app/), testes pytest vs NumPy/SciPy (testes/), README.md e RELATORIO.md (formulas, validacao, 3 descobertas) e graficos em assets/.

<https://github.com/gabrielrichardy/lab-estatistico>

Video nao listado no YouTube (ou Drive com acesso liberado): dataset (30 s) - cada modulo rodando - explicacao de um trecho do nucleo - melhor achado.

https://youtu.be/COLE_AQUI_O_LINK_DO_VIDEO

5.1. Dataset

Body Performance Data reúne 13.393 avaliacoes de desempenho fisico (altura, peso, percentual de gordura, pressao, forca, flexibilidade, abdominais, salto; genero e classe A-D). Atende aos criterios: mais de 1.000 registros, 10 variaveis numericas e 2 categoricas.

Circuitos 1-2: nucleo estatistico proprio (media, mediana, moda, amplitude, variancia/dp amostral e populacional, quartis/percentis type 7, coeficiente de variacao, covariancia e Pearson) validado em 44 testes contra NumPy/SciPy (rtol 1e-10) + estatistica descritiva interativa com tabelas de frequencia, histograma/boxplot, outliers (IQR) e interpretacao automatica. Circuitos 3-4: simulacao de Monte Carlo (Lei dos Grandes Numeros e Teorema Central do Limite) com parametros controlaveis e ajuste de distribuicoes teoricas (Normal e Exponencial/Uniforme) com parametros estimados dos dados. Circuitos 5-6: regressao linear por minimos quadrados implementada na mao (equacao, R2, predicao interativa) e 3 descobertas documentadas no relatorio.

1) A altura e a variavel mais homogenea: CV = 5,00% (media 168,6 cm; dp 8,4), contra CV de 37,0% na idade e 35,9% nos abdominais - a amostra varia muito mais em condicionamento do que em estatura. 2) Peso e percentual de gordura nao caminham juntos: $r = -0,08$, enquanto altura x peso dao $r = 0,73$ e abdominais x salto $r = 0,75$ - mais peso nao implica mais gordura relativa, pois massa muscular pesa mais. 3) O dataset mistura formas: idade e assimetrica a direita (media 36,8 > mediana 32,0; cauda de idosos) enquanto salto e abdominais sao assimetricos a esquerda - nao existe 'a curva dos dados', cada variavel pede modelo proprio.

Suporte de regressao: height_cm x weight_kg ajustam $y = 1.04 \cdot x - 108.22$ com $r = 0.7349$ e $R^2 = 0.5401$ (54.0% da variacao do peso explicada linearmente pela altura).

Histograma de height_cm (15 classes, Sturges)




OLS: height_cm x weight_kg — $y = -108.2 + (1.042) \cdot x$ ($R^2 = 0.5401$)

140

observações

TCL: distribuição das médias de systolic (n=30, 5.000 repetições)



Figuras geradas pela propria aplicacao (scripts/gerar_graficos.py): histograma de altura, regressao altura x peso e distribuicao das medias amostrais (TCL, n=30).

Obse

* Preencha (SUBSTITUIR) em identificacao, repositorio e video. * Teste os 3 links em uma janela anonima do navegador antes de enviar. * Envie o PDF no ambiente virtual da disciplina (Adicionar envio > anexar > Salvar mudancas), dentro do prazo.